

UNIVERSITÀ DEGLI STUDI DI UDINE

---

Dipartimento di Matematica e Informatica

Corso di Laurea Triennale in Informatica

Tesi di Laurea

**PRE-DESTINAZIONE:  
MODELLI ED ESPERIMENTI PER  
LA PREVISIONE DI TRAIETTORIE**

Relatore:

Prof. IVAN SCAGNETTO

Laureando:

ALESSIO PELLIN

---

ANNO ACCADEMICO 2014-2015



# Introduzione

Negli ultimi anni, grazie all'avvento di nuove tecnologie nel settore delle reti wireless e dei dispositivi mobili le reti wireless sono diventate una parte fondamentale dell'infrastruttura delle telecomunicazioni. Oramai l'utente pretende che la qualità delle reti wireless siano almeno pari a quelli forniti via cavo visti gli incredibili passi avanti che le reti cellulari hanno ottenuto negli ultimi 5-6 anni. Basti pensare alla nuove reti 4G (LTE e WiMax) che promettono velocità nell'ordine sui 5-8 Mbps di Mbit/s in download e contro le attuali linee ADSL con una media di 15 Mbps promessi. In più le attuali società telefoniche forniscono più facilmente reti wireless ad alta velocità piuttosto che reti cablate visto la diffusione di apparecchiature mobili quali smartphone, tablet, ecc [Vedi Figura 1]. In più con gli attuali progetti di Facebook e Google sulla progettazione di droni capaci di portare reti WiFi o LTE si punta ad avere una copertura quasi totale del suolo mondiale.

Questa sempre più crescente utenza connessa in movimento ha fatto accrescere l'interesse di acquisire informazioni contestuali per poter offrire servizi di maggior interesse e utilità per l'utente. L'informazione contestuale può riferirsi alla posizione dell'utente, all'ora attuale, a proprietà fisiche come la temperatura, ecc. La gestione efficiente del contesto richiede un dettagliato data modeling ottenuto con processi specifici di classificazione, inferenza e predizione.

Certo è difficilmente comprendere cosa può essere considerato context aware, senza prima avere dato una definizione di contesto. La principale definizione di contesto è la seguente: *Il contesto è qualsiasi informazione che può essere usata per caratterizzare la situazione di una entità. Un'entità è una persona, un luogo ad un oggetto considerata rilevante all'interazione fra l'utente e l'applicativo, inclusi l'utente e l'applicativo stessi* [1]. Il contesto dunque è specificato mediante i valori di opportuni parametri, rappresentanti l'attività di un'entità. L'approccio orientato al contesto quindi permette all'entità di adattarsi all'ambiente, offrendo superiori vantaggi e possibilità ai nuovi applicativi. Una delle proprietà che maggiormente si desidera nel mobile context-awareness è la loro possibilità di poter effettuare previsioni, caratteristica che permetterebbe lo sviluppo di nuove, avanzate applicazioni.



Figura 1: Copertura LTE mondiale

Nel 2001, il Computer Science and Telecommunications Board (CSTB) del Consiglio Nazionale della Ricerca degli Stati Uniti d'America ha riunito una commissione di esperti per eseguire una ricerca sulle opportunità certe e sui possibili sviluppi relativi all'interazione tra le comunità di ricerca geo-spaziale ed informatica. Nella relazione prodotta dalla commissione [2], si evidenzia come l'ubicazione dell'utente sia uno dei fattori fondamentali nelle diverse definizioni di contesto che sono state proposte in letteratura. La centralità di tale componente è la possibilità, fornita dalle attuali tecnologie mobili, di rilevare in modo sufficientemente preciso, semplice e continuativo, la posizione geografica degli utenti, fanno di questo settore un campo di ricerca attualmente molto attivo.

Contemporaneamente alla nascita dei servizi context aware, è dunque nata la necessità di avviare una ricerca mirata al miglioramento delle prestazioni nella previsione delle traiettorie. Tale ramo di ricerca ovviamente mutua gran parte della natura delle applicazioni context aware. In questo caso però le informazioni memorizzate si riducono a semplici dati spaziali e temporali, che dunque non rischiano di ledere la privacy della persona come invece possono essere portati a fare con applicativi context aware, che per loro natura cercano di tracciare tutti gli aspetti (gusti, personalità) dell'utenza. La conoscenza della posizione di oggetti mobili ha dunque condotto allo sviluppo di applicazioni e servizi che sono stati catalogati location-based, che necessitano di conoscere la posizione approssimata di un oggetto mobile per operare. Esempio di ta-

li servizi sono gli applicativi di navigazione, gestori di traffico e la pubblicità location-based. In uno scenario tipico, il dispositivo mobile che sta fornendo un determinato servizio, periodicamente informa il framework di posizionamento della attuale posizione.

Nell'ultimo decennio anche i sistemi di sistemi di posizionamento sono migliorati. da un'accuratezza di decine di metri, si è ormai arrivati ad avere una precisione di pochi metri anche per utilizzi civili. La ricerca di una precisione sempre più alta a disposizione di tutti ha portato alla creazione di sistemi di posizionamento alternativi la GPS quali GLONASS (Militare russo), COMPASS (Cina), Galileo (Europa) e IRNSS (India) stanno cercando di imporsi come alternativa al sistema Americano.

Grazie alla copertura sempre crescente di reti wireless e sistemi di posizionamento la context aware non è più incentrata sulla ricerca della posizione attuale dell'utente, ma sulle possibili destinazioni e percorsi nel breve e lungo termine. Grazie ad una metodologia si cerca di predire la posizione per anticipare i movimenti dell'utente e quindi cercare di eseguire un pre-fetch del servizio sulla località prevista. Lo sviluppo di pratiche ed accurate tecniche di previsione degli spostamenti può dunque aprire le porte a molti applicativi quali prenotazione di risorse, servizi location-based, ma anche migliorare la pianificazione e gestione delle aree urbane, grazie ad una migliore analisi del flusso urbano.

Ovviamente la possibilità di tracciare la posizione attuale dell'utente da sola non è sufficiente ad effettuare previsioni sul futuro dell'utente. In un articolo pubblicato qualche anno fa [3], nel quale si afferma come osservando i dati storici relativi ai movimenti di un utente (collezionati con diverse tecniche, nel caso citato accedendo alle basi di dati di una compagnia telefonica) sia possibile individuare pattern di movimento, ed prevedere correttamente il luogo in cui si trova una persona per il 93% del tempo. Da tali studi emerge come ciascun individuo abbia un insieme di località che raramente lascia, e nelle quali si sposta con grande regolarità. Gli utenti che risiedono stabilmente in un raggio di 6 miglia hanno un tasso di predicibilità della posizione che va dal 93% al 97%, ma anche nel caso in cui il raggio aumenti di centinaia di miglia, la percentuale delle previsioni rimane alta, stabilizzandosi al 93% di successo. In tale articolo vengono inoltre indicati dei legami tra le località frequentate dall'individuo e le ore della giornata. In particolare si evince come in certi orari di transizione (prima o dopo l'orario di lavoro, oppure durante le pause pranzo) le previsioni sul luogo in cui si trova l'utente vedano un brusco peggioramento dei risultati; comunque la percentuale che l'utente si trovi in un qualsiasi momento della giornata nella località più visitata è molto alta (del 70%).

# 1 Obiettivi della tesi

Già in precedenti lavori di tesi svoltisi nell'Università degli Studi di Udine è stato presentato un algoritmo di previsione delle traiettorie basato sul modello della fisica dei campi elettrici, dove le località maggiormente importanti per l'individuo erano caratterizzate da forze attrattive e le meno importanti da forze nulle se non addirittura repulsive. Tale algoritmo è denominato ARDA, è stato presentato unitamente ad una nuova proposta di pesatura dell'importanza delle località che prende il nome di SpaceRank, il quale andava ad affiancare altri indici di valutazione delle località quali TotalTime (il tempo totale che l'individuo passa in una località), AverageTime (il tempo medio che l'individuo passa in una certa località durante una visita), NumberOfVisits (il numero di volte che l'utente passa per una certa località), e combinazioni di tali indici. Il lavoro svolto in una precedente tesi [3] proponeva:

- l'implementare dell'algoritmo di previsione ARDA utilizzando vari indici di valutazione dell'importanza delle località, con diverse suddivisioni di territorio
- confronto dei risultati di previsione ottenuti evidenziando il comportamento dell'algoritmo ARDA rispetto a due altri algoritmi di previsione (il primo che suppone l'utente prosegua la propria corsa in linea retta mantenendo la velocità media, il secondo che suppone l'utente prosegua il proprio percorso rimanendo in un intorno del punto rilevato);
- valutando la stabilità degli algoritmi proposti eseguendo dei test anche su una diversa raccolta di punti GPS (messa a disposizione dal Prof. Thad Starner) riguardante un territorio di dimensioni e varietà di movimenti maggiori;
- analisi del comportamento dell'algoritmo nelle previsioni delle destinazioni finali, eseguite lungo quattro milestone virtuali poste lungo i percorsi (inizio, 25%, 50% e 75% del tracciato).

Questa tesi prende in esame l'algoritmo e i dati di quella precedentemente descritta e si pone i seguenti obiettivi:

- Traduzione degli algoritmi dal linguaggio Python a Java e migliorarne alcuni aspetti;
- Unificare le procedure di test per i vari indici;
- Sviluppo di un'interfaccia per l'utilizzo al di fuori della riga di comando;
- Sviluppo di un sistema di visualizzazione ed esportazione dei test eseguiti.

## 2 Struttura della tesi

Lo scritto della tesi si divide in quattro principali parti. Nella prima parte si occupa di presentare gli algoritmi presi in esame cercando di metterne in evidenza non solo gli aspetti modellistici, ma anche i problemi implementativi. Nella seconda parte si dà ampio spazio ai risultati ottenuti sia nei risultati che a livelli prestazionali. Infine la terza parte è quella conclusiva, in cui si riassume il lavoro svolto traendo le somme sul lavoro svolto, presentando i punti di forza e di debolezza delle soluzioni adottate dando anche dei gli spunti di riflessione su eventuali sviluppi.

Le tre parti sopra esposte in realtà sono state svolte con diversa estensione, cercando di rispettare le gerarchie logiche. La prima sezione è racchiusa nel Capitolo 1 e 2. Il primo capitolo espone i concetti e la teoria sugli algoritmi scelti, vista l'importanza di riuscire a proporre nel modo più esauriente possibile le soluzioni algoritmiche adottate. Il secondo capitolo invece si sofferma sulle scelte di sviluppo fatte, gli accorgimenti fatti per migliorare gli algoritmi e il funzionamento del programma. La seconda parte invece si sviluppa nei seguenti due capitoli. Il Capitolo 3 e 4. Nel terzo capitolo si espongono i risultati ottenuti comparandoli con quelli ottenuti nella tesi precedente lasciando spazio a grafici e comparative cercando di capire il perché delle differenze. Nel quarto capitolo si fa una piccola osservazione sulle prestazioni delle 2 versioni facendo anche una comparativa con i tempi stimati al tempo della tesi originale. Infine la quarta parte, quella conclusiva, nella quale si cerca con il quinto capitolo di riassumere il lavoro svolto, evidenziando i risultati ottenuti e cercando di proporre come poter ulteriormente sviluppare la ricerca e miglioramenti prestazionali.





# Indice

1	Obiettivi della tesi . . . . .	vi
2	Struttura della tesi . . . . .	vii
<b>1</b>	<b>Teoria sugli algoritmi</b>	<b>1</b>
1.1	Space Rank . . . . .	1
1.1.1	Criteri di valutazione dell'importanza . . . . .	1
1.1.2	PageRank . . . . .	3
1.1.3	SpaceRank . . . . .	5
1.2	ARDA . . . . .	8
1.2.1	Formalizzazione del problema . . . . .	8
1.2.2	Modello astratto di previsione . . . . .	9
1.2.3	ARDA . . . . .	12
<b>2</b>	<b>Conversione e sviluppo</b>	<b>17</b>
2.1	Analisi e scelte implementative . . . . .	17
2.1.1	Conversione . . . . .	17
2.1.2	Unificazione dei valori di default . . . . .	18
2.1.3	Modifiche fatte . . . . .	18
2.2	Interfaccia Java . . . . .	19
2.2.1	Visualizzazione plot matrici . . . . .	20
<b>3</b>	<b>Comparative sui risultati ottenuti</b>	<b>21</b>
3.1	Matrici d'importanza . . . . .	21
3.1.1	Dati Python . . . . .	21
3.1.2	Dati Java . . . . .	21
3.2	ARDA . . . . .	21
3.2.1	Dati Python . . . . .	21
3.2.2	Dati Java . . . . .	21
3.3	Valutazioni complessive . . . . .	21
	<b>Bibliografia</b>	<b>23</b>



# Capitolo 1

## Teoria sugli algoritmi

### 1.1 Space Rank

Nello sviluppo di algoritmi di previsione della destinazione risulta di fondamentale importanza avere a disposizione una solida base di conoscenza relativa alle abitudini degli utenti. In particolare è necessario conoscere quali sono i luoghi importanti per un utente: tali luoghi nella maggior parte dei casi risulteranno essere le destinazioni dei suoi spostamenti. Tuttavia, in questo particolare contesto, le definizioni del concetto di importanza e dei relativi indici di valutazione compongono un campo di ricerca di notevole interesse.

In questa sezione viene proposta una metodologia di analisi dei dati volta a stimare l'importanza delle località sulla base dei comportamenti degli utenti. L'obiettivo è quello di utilizzare i dati relativi alle visite effettuate dagli utenti nelle singole località in modo tale da ottenere dei valori che rappresentino l'importanza che esse assumono nelle abitudini degli utenti.

#### 1.1.1 Criteri di valutazione dell'importanza

La letteratura presenta diversi casi in cui risulta necessario lo sviluppo di sistemi di valutazione dell'importanza delle località. Esempi di tale necessità si trovano in [4], nel quale viene presentato l'algoritmo **Predestination**, che appunto esegue una suddivisione del territorio ed una valutazione dell'importanza di ciascuna regione, per indicarne l'appetibilità rispetto all'utente esaminato. Un altro esempio che va citato è inoltre l'articolo [5], nel quale si propone un modello gravitazionale atto a considerare i flussi di una città per decidere in quali zone sia preferibile andare ad aprire nuove attività commerciali. In un simile contesto risulta evidente l'apporto che un appropriato criterio di valutazione di importanza delle regioni possa dare. Definire quali siano le località importanti per un utente non è tuttavia un problema banale. Alcuni studi [6]

hanno dimostrato che le probabilità che ciascuno di noi si trovi in una certa località sono legate alla legge di potenza, ovvero che tali probabilità relativamente ad una località sono proporzionali all'inverso della posizione occupata dalla località stessa in una scala di importanza. Questo implica l'esistenza di un ordinamento delle località basato sull'importanza che esse hanno per ciascuno di noi. Rimane da considerare come ottenere informazioni utili alla definizione degli interessi del singolo utente. Per tale scopo possiamo sempre utilizzare [6], in quanto esso dimostra chiaramente come le persone tendano a frequentare sempre gli stessi luoghi, dunque a passare sempre per le stesse aree. Dopo tale osservazione risulta chiaro come sia sufficiente rilevare ed analizzare i comportamenti passati dell'utente per poterne elencare gli interessi, e dunque prevederne i movimenti. Per definire l'importanza che ciascuna località ha per l'utente, e dunque intuitivo adottare i seguenti indici:

- $\#visits$ : il numero di volte in cui l'utente è stato nella località;
- $avgTime$ : il tempo medio delle visite effettuate dall'utente nella località;
- $totTime$ : il tempo totale passato dall'utente nella località durante le sue visite.

La potenza di questi indici e il relativo basso costo computazionale per la rilevazione, effettuabile a partire da una qualsiasi collezione di dati, previa standardizzazione della struttura del contenuto. Purtroppo però tale approccio ha anche una importante debolezza, difatti questi indici presi separatamente, possono dare solo una visione parziale delle abitudini degli utenti, e per alcune applicazioni potrebbero non essere sufficienti. Ad esempio, considerando solamente  $\#visits$ , le località in cui l'utente solamente passa e quelle in cui l'utente si ferma per lungo tempo sono equivalentemente valorizzate. Similmente, il semplice uso di  $avgTime$  può portare alla equiparazione di località frequentemente visitate a quelle che vengono raramente raggiunte. Migliore dunque sembrerebbe l'utilizzo dell'indice  $totTime$ , in quanto esso riesce a valorizzare sia le lunghe permanenze che un alto numero di passaggi su una particolare cella. Rimane comunque il problema di come riuscire a differenziare le celle con stesso  $totTime$ , difficoltà che si è cercato di superare con l'introduzione di un nuovo indice derivato, ottenuto dalla combinazione lineare degli indici  $\#visits$  ed  $totTime$ : tale indice è stato qui definito come  $combLinear$ , e sembrerebbe la soluzione più equa, benché faccia sorgere il problema di come pesare i due indici durante il calcolo della combinazione lineare.

Come abbiamo osservato, diverse proposte per la rilevazione dell'importanza delle località sono già state definite, ognuna con pregi e difetti. Alla luce di ciò, è risultato interessante unire alla definizione di un algoritmo di previsione di traiettorie basato sulla pesatura delle località anche la stesura e relativa

comparazione di un nuovo indice che potesse competere prestazionalmente con quelli già definiti. Nella ricerca del migliore approccio possibile a tale problema inevitabile è stato imbattersi nell'algoritmo di PageRank [7], largamente utilizzato nei motori di ricerca per la catalogazione e l'ordinamento dei documenti ipertestuali come le pagine web. Esso, a partire da una mappatura dei collegamenti ipertestuali in un grafo pesato, ricava una stima dell'importanza dei documenti considerati. Similmente l'indice *spaceRank*, da esso ispirato, si propone di codificare i movimenti osservati degli utenti al fine di poter analizzare il grafo creato per ottenere una stima dell'importanza delle località comprese nell'area analizzata.

### 1.1.2 PageRank

L'algoritmo di PageRank [7] ha avuto origine nel 1995 da un progetto di ricerca della Stanford University, a cura di Larry Page. A rendere famoso questo algoritmo è stato lo sviluppo e la successiva crescita negli anni del primo motore di ricerca ad utilizzarlo per l'ordinamento dei risultati, Google. L'obiettivo dell'algoritmo di PageRank è quello di misurare l'importanza di ciascun elemento di un insieme di documenti con collegamenti ipertestuali. A tal fine viene calcolato, per ciascun documento, un valore numerico che rappresenta la probabilità che una persona arrivi a quel dato documento scegliendo ciclicamente a caso uno dei collegamenti presenti nel documento ipertestuale che sta leggendo. Il processo matematico, utilizzato per il calcolo del valore numerico da assegnare a ciascuno dei documenti, si basa sulle catene di Markov. Dato un insieme di documenti ipertestuali, viene innanzitutto calcolata la matrice relativa alle citazioni. Quest'ultima è una matrice  $n \times n$ , dove  $n$  è il numero dei documenti presenti nell'insieme. Su ciascuna riga di tale matrice vengono inseriti i valori relativi ai collegamenti ipertestuali che puntano a ciascuno dei documenti indicati dalle colonne. Su tale matrice viene effettuata una normalizzazione tale da rendere la somma dei valori di ciascuna riga pari ad 1. La matrice risultante è la matrice di adiacenza del grafo delle citazioni dell'insieme di documenti. Il grafo delle citazioni così creato può essere interpretato come una catena di Markov ed il calcolo dell'autovettore dominante della matrice di adiacenza definisce la probabilità di trovarsi in ciascuno degli stati della catena di Markov durante una camminata casuale, ovvero la probabilità di raggiungere ciascuno dei documenti scegliendo ciclicamente a caso uno dei collegamenti ipertestuali contenuti nei documenti che vengono presentati, ovvero il valore di PageRank. Tuttavia un tale calcolo presenterebbe due problemi.

Il primo problema, a livello matematico, è relativo alla catena di Markov, la quale potrebbe non essere ergodica. Una catena di Markov si definisce ergodica se ciascuno stato della catena (ovvero ciascun nodo del grafo) è:

- aperiodico: se il suo periodo è pari a 1, ovvero se lo stato non deve sempre occorrere dopo un multiplo di un certo numero di passi;
- ricorrente positivo: se in una camminata casuale infinita c'è sempre probabilità di ritornare in uno stato già visitato in un numero finito di passi.

Il calcolo dell'autovettore dominante di una matrice relativa ad una catena di Markov non ergodica potrebbe non convergere e non si avrebbe, quindi, un limite stabile da poter utilizzare come valore di PageRank.

Il secondo problema è invece attinente alla metafora utilizzata da questa metodologia. Risulta infatti difficile pensare ad un utente che sfogli un insieme di documenti unicamente seguendo i collegamenti ipertestuali e senza mai abbandonare un documento per uno qualsiasi dei documenti dell'insieme. Entrambi i problemi descritti possono essere risolti mediante l'utilizzo di quella che viene comunemente definita matrice di teletrasporto. Quest'ultima è una matrice  $n \times n$  che definisce un grafo con un arco di pari peso tra ciascuna coppia di nodi. Tale grafo può essere interpretato come una catena di Markov in cui ad ogni passo è possibile passare dallo stato attuale ad uno qualsiasi degli stati della catena (compreso quello attuale). Dalla combinazione lineare delle normalizzazioni delle due matrici descritte si ottiene la matrice il cui autovettore dominante contiene i valori di PageRank effettivamente utilizzati quali stima dell'importanza dei documenti dell'insieme. Per tale combinazione lineare viene utilizzato un fattore  $d$ , comunemente definito fattore di salto, che definisce la probabilità, stabilita a priori, che l'utente effettui un salto dal documento in cui si trova ad uno qualsiasi dei documenti dell'insieme, ovvero di seguire i collegamenti definiti dalla matrice di teletrasporto. Dunque, la matrice utilizzata per il calcolo dei valori di PageRank sarà:

$$P = (1 - d)xA + dT \quad (1.1)$$

dove  $A$  è la matrice di adiacenza normalizzata del grafo delle citazioni,  $T$  è la matrice di teletrasporto normalizzata e  $d$  è il fattore di salto. Per il calcolo dell'importanza delle pagine web, dai motori di ricerca viene solitamente utilizzato un fattore di salto pari a 0.15.

Una volta calcolata la matrice di PageRank  $P$ , non rimane che utilizzarla per calcolare la matrice di Importanza  $M_{imp}$  utilizzando il metodo delle potenze per ricavarne l'autovettore dominante. Sia  $x$  vettore qualsiasi di dimensione  $n$ , ed  $P$  la matrice di PageRank otterremo la matrice  $M_{imp}$  come segue:

$$M_{imp} = \lim_{k \rightarrow +\infty} xP^k \quad (1.2)$$

La formulazione proposta in realtà non viene mai implementata in quanto presenta problemi di overflow ed underflow. Per evitarli è necessario eseguire ad ogni passo una normalizzazione del vettore ottenuto, costruendo una successione definita come segue:

$$\begin{cases} M_{aux}(i+1)M_{imp}(i)P \\ \beta_{i+1} = \text{normaDue}[M_{aux}(i+1)] \\ M_{imp}(i+1) = \frac{M_{aux}(i+1)}{\beta_{i+1}} \end{cases} \quad (1.3)$$

che termina non appena  $M_{imp}(n) - M_{imp}(n-1) < \varepsilon$  con  $\varepsilon$  scelto dall'utente, lasciando quindi  $M_{imp} = M_{imp}(n)$ .

### 1.1.3 SpaceRank

In questo capitolo viene proposto un approccio all'analisi dei comportamenti degli utenti osservati basato sull'utilizzo dell'algoritmo di PageRank. Questo approccio è stato chiamato in [8] SpaceRank. Come per l'algoritmo di PageRank, per la costruzione della matrice, il cui autovettore dominante conterrà i valori di valutazione delle località, vi sono diversi passaggi che, dopo una definizione più formale del problema, sono esposti nei seguenti paragrafi.

#### Formalizzazione del problema

Dato un insieme di informazioni relative all'ubicazione di un insieme di utenti in una data area e lungo un dato periodo di tempo, l'obiettivo è quello di stimare l'importanza delle località dell'area di interesse sulla base dei dati a disposizione. Per effettuare tale analisi, si rende innanzitutto necessario discretizzare l'area di interesse in un insieme di sotto-aree  $L = l_0, l_1, \dots, l_{n-1}$  che chiameremo località. In tale suddivisione non è necessario che le località siano della stessa dimensione ma, per semplicità, nella seguente discussione supporremo che lo siano. Negli esempi in Figura 2.1, i nodi del grafo, che rappresentano le località, sono disposti in griglie quadrate. Definiamo  $N_i$  come l'insieme di tutte le località vicine ad  $l_i$ , ovvero come l'insieme di tutte le località raggiungibili da  $l_i$  con un solo passaggio, compresa  $l_i$  stessa, ed  $N$  come l'insieme di tutti gli insiemi  $N_i$ . Supponiamo, quindi, di disporre dei dati relativi al campionamento dell'ubicazione e della velocità di spostamento di uno o più utenti durante un periodo di tempo. Per ciascun utente  $u$  è possibile creare un registro storico  $R_u = r_0, r_1, r_2, \dots$  contenente i dati a disposizione per quell'utente, in cui ogni elemento è una tripla  $r_i = (t, l, s)$ , dove  $t$  è la marcatura temporale relativa all'istante in cui è stata effettuata la campionatura,  $l \in L$  è la località registrata ed  $s$  è la velocità di spostamento dell'utente

in quell'istante. Sia, infine,  $R = R_0, R_1, \dots, R_m$  l'insieme dei registri relativi agli  $m$  utenti del campione. Dati gli insiemi  $L, N$  ed  $R$ , l'obiettivo è quello di ottenere un valore numerico che stimi l'importanza di ciascuna località  $l \in L$ .

FIGURA 2.1

### Matrice basata sul registro storico dei dati

Il primo passo della procedura di calcolo di SpaceRank prevede la mappatura dei registri relativi alla campionatura dell'ubicazione degli utenti in un grafo pesato diretto, il cui scopo è di rappresentare le abitudini osservate degli utenti. Sia  $A$  la matrice di adiacenza  $n \times n$  (dove  $n$  è la cardinalità di  $L$ ) del grafo delle abitudini. Inizialmente, sia  $A[i, j] = 0$  per ciascun valore di  $i$  e di  $j$  compresi tra 0 ed  $n-1$ . Dato l'insieme  $R$ , per ciascun  $R_u \in R$ , per ciascuna coppia di elementi di  $R_u$  temporalmente successivi  $r_x$  ed  $r_{x+1}$ , deve essere eseguito l'aggiornamento  $A[i, j] = A[i, j] + 1$ , dove  $l_i$  è la località indicata dalla tripla  $r_x$  ed  $l_j$  è la località indicata dalla tripla  $r_{x+1}$ . Compiuto tale procedimento, ogni elemento  $A[i, j]$  della matrice  $A$  conterrà il numero di movimenti (ovvero passaggi da una località ad un'altra) dalla località  $i$  alla località  $j$  effettuati dagli utenti durante il periodo di osservazione. Si noti che, nel caso in cui un utente si trovasse nella stessa località durante due campionamenti temporalmente successivi, tale comportamento verrebbe mappato nel grafo delle abitudini come un ciclo sullo stesso nodo; definiremo tale tipologia di movimenti come permanenze. Ad esempio in Figura 2.1 (a) viene illustrato un grafo che mappa i possibili spostamenti in un'area suddivisa in una griglia di quattro località disposte in una griglia  $2 \times 2$  (nella figura non sono visibili i pesi assegnati agli archi). Tramite un processo di normalizzazione delle righe della matrice  $A$  è possibile ottenere una matrice  $\bar{A}$ , in cui la somma dei valori di una singola riga sia ciascun valore  $\bar{A}[i, j]$  contenuto in tale matrice può essere interpretato come la probabilità che l'utente effettui un movimento dalla località  $i$  alla località  $j$  sulla base delle abitudini osservate, contenute nell'insieme dei registri  $R$ . Il procedimento più semplice, ma non l'unico possibile, per ottenere una tale normalizzazione è quello di dividere ciascun elemento di ciascuna riga della matrice per la somma dei valori della riga a cui esso appartiene.

### Matrice di transizione

La matrice  $\bar{A}$  finora sviluppata nell'algoritmo di Space Rank non è sicuramente la soluzione definitiva per la corretta formalizzazione del problema, in quanto si avrebbe una probabilità pari a zero di raggiungere una località mai visitata prima dall'utente e la catena di Markov relativa al grafo delle abitudini potrebbe non essere ergodica. A tal fine può essere creata una matrice  $\bar{B}$ ,



che definiremo come matrice di transizione, che rappresenti un grafo avente un nodo per ciascuna località  $l \in L$  ed un arco per ciascuna coppia di località contigue. Sia dunque  $\bar{B}$  la matrice definita come:

$$\bar{B}[i, j] = \begin{cases} \frac{1}{c_i} & \text{se } j \in N_i \\ 0 & \text{altrimenti} \end{cases} \quad (1.4)$$

dove  $c_i$  è la cardinalità dell'insieme  $N_i$ . Tale matrice è già normalizzata e descrive un grafo corrispondente ad una catena di Markov ergodica in cui si ha la stessa probabilità di effettuare ad ogni passo una transizione dallo stato attuale ad uno qualsiasi degli stati che rappresentano le località vicine a quella in cui si trova l'utente (compresa quest'ultima). Ad esempio in Figura 2.1 (b) viene illustrato il grafo di una possibile matrice  $\bar{B}$  relativa ad un'area suddivisa in quattro località disposte in una griglia  $2 \times 2$  (nella figura non sono visibili i pesi assegnati agli archi). In questo caso particolare, l'insieme dei vicini di ciascuna località comprende tutte le località dell'area di interesse. Lo stesso vale per la località centrale in Figura 2.1 (c), dove viene illustrato il grafo di una possibile matrice  $\bar{B}$  relativa ad un'area suddivisa in nove località disposte in una griglia  $3 \times 3$  (nella figura non sono visibili i pesi assegnati agli archi), ma non per le altre località di questo secondo esempio, dalle quali è possibile raggiungere solo alcune località (4 o 6 a seconda della posizione).

### Combinazioni delle matrici

Ottenute, dunque, le due matrici  $\bar{A}$  e  $\bar{B}$ , che rappresentano rispettivamente le abitudini osservate degli utenti e la conformazione dell'area d'interesse, è possibile combinare le due matrici per ottenere una matrice normalizzata a cui possa essere applicato il calcolo dell'autovettore dominante, come avviene nel caso del calcolo di PageRank. Come per il calcolo del PageRank, deve essere utilizzato un fattore di combinazione  $d$ , che nel caso dei documenti ipertestuali viene comunemente definito fattore di salto. È che in questo contesto può essere definito come fattore di comportamento non abitudinario, dato che definisce la percentuale di probabilità con cui deve essere presa in considerazione la possibilità che l'utente si muova al di fuori delle abitudini osservate. La matrice a cui verrà dunque applicato il calcolo dell'autovettore dominante sarà:

$$S = (1 - d)x\bar{A} + dx\bar{B}$$

In prima istanza, il valore  $d = 0.15$ , comunemente utilizzato per il calcolo del PageRank, può essere preso in considerazione come un buon valore di combinazione delle due matrici. Un valore minore darebbe maggiore importanza alle abitudini osservate, mentre un valore superiore porterebbe a prendere maggiormente in considerazione un comportamento generico e non legato alle abitudini

osservate. I due casi estremi porterebbero a  $S = \bar{A}$ , con  $d = 0$ , ed a  $S = \bar{B}$ , con  $d = 1$ . Ovviamente quest'ultimi due casi sono da escludere: il primo perché porterebbe agli stessi problemi a causa dei quali è stata introdotta nel calcolo la matrice  $\bar{B}$ ; il secondo perché non darebbe alcuna effettiva informazione relativa ai comportamenti osservati degli utenti.

### Calcolo della Matrice di Importanza

Una volta calcolata la matrice di SpaceRank  $S$ , non rimane che utilizzarla per calcolare la matrice di Importanza  $M_{imp}$  utilizzando il metodo delle potenze per ricavare l'autovettore dominante.

Sia  $x$  vettore qualsiasi di dimensione  $n$ , ed  $S$  la matrice di SpaceRank otterremo la matrice  $M_{imp}$  come segue:

$$M_{imp} = \lim_{k \rightarrow +\infty} xS^k \quad (1.5)$$

Ovviamente per calcolare effettivamente  $M_{imp}$  sarà sufficiente eseguire la seguente successione libera da problemi di undreflow ed overflow:

$$\begin{cases} M_{aux}(i+1)M_{imp}(i)S \\ \beta_{i+1} = \text{normaDue}[M_{aux}(i+1)] \\ M_{imp}(i+1) = \frac{M_{aux}(i+1)}{\beta_{i+1}} \end{cases} \quad (1.6)$$

che termina non appena  $M_{imp}(n) - M_{imp}(n-1) < \varepsilon$  con  $\varepsilon$  scelto dall'utente, lasciando quindi  $M_{imp} = M_{imp}(n)$ .

## 1.2 ARDA

Come esposto nell'introduzione, negli ultimi anni, specialmente nel contesto dei sistemi mobili, sono stati sviluppati diversi algoritmi per la previsione delle traiettorie degli utenti. Nella maggior parte dei casi essi si basano su complicati modelli matematici e statistici operanti su informazioni raccolte nel passato. In questo capitolo, dopo una breve formalizzazione del problema della previsione delle traiettorie, viene proposto un modello astratto presentato in [8] per la previsione delle stesse basato sull'utilizzo di una semplice metafora legata alla fisica dei campi elettrici.

### 1.2.1 Formalizzazione del problema

Si prenda ad esempio un generico oggetto in movimento. Possiamo indicare tale oggetto generico come oggetto della previsione (ODP). Assumiamo che

l'ODP si muova su una superficie bidimensionale; ciò ci permette una semplice rappresentazione bidimensionale del problema, ma l'estensione al caso tridimensionale è di semplice realizzazione. L'obiettivo è quello di determinare la probabilità con cui l'ODP, che all'istante attuale  $t_0$  è posizionato nel punto  $(x_0, y_0)$  sulla superficie, si verrà a trovare in ciascuno dei punti del piano ad un certo istante  $t_i$  nel futuro, dato un suo attuale vettore di spostamento  $\vec{v}_0$ . In prima istanza, questo equivale a cercare una funzione a sette parametri:

$$p(x_0, y_0, t_0, \vec{v}_0, t_i, x, y) \quad (1.7)$$

che calcoli un valore di probabilità per ciascun punto  $(x, y)$  del piano. Normalmente, gli spostamenti quotidiani di una persona non sono casuali, ma guidati dall'interesse della persona stessa verso un piccolo insieme di luoghi [6]. Risulta quindi ovvio che la posizione di tali oggetti di interesse influenzi il movimento dell'ODP sulla superficie. Interpretando l'interesse dell'ODP verso questi luoghi come un'attrazione esercitata su di esso dagli stessi, possiamo dunque posizionare sulla superficie dei punti di interesse, che possono rappresentare case, uffici, negozi, città, stazioni, ecc. Quindi l'obiettivo è quello di trovare una qualche funzione del tipo:

$$p[k_1, \dots, k_n](x_0, y_0, t_0, \vec{v}_0, t_i, x, y) \quad (1.8)$$

che calcoli la probabilità che  $(x, y)$  sia la posizione dell'ODP al tempo  $t_i$ , dato uno schema fissato di punti di interesse sulla superficie  $[k_1, \dots, k_n]$ .

### 1.2.2 Modello astratto di previsione

Le metafore legate al mondo reale sono largamente utilizzate in diversi campi dell'informatica. Questo si deve al fatto che l'utilizzo delle metafore fornisce una base comune per la condivisione di idee tramite modelli ampiamente conosciuti e studiati. In questo capitolo viene presentato un modello astratto, per la previsione delle traiettorie degli utenti nel contesto dei sistemi mobili, che sfrutta una metafora legata alla fisica dei campi elettrici.

#### Modello gravitazionale

Un recente studio [6] ha confermato che ciascuno di noi è legato ad un insieme di località che possono essere definite importanti. Le analisi condotte indicano che vi sono alte probabilità che in un qualsiasi momento una data persona si trovi in due o tre località importanti e basse probabilità che si trovi in un qualsiasi altro posto. Da queste considerazioni si può dedurre che se un utente è in movimento ci sono alte probabilità che si stia dirigendo verso uno

di questi punti di interesse. Per ciascuno di noi vi sono infatti alcuni tragitti molto utilizzati che sono quelli che ci portano da una località per noi importante ad un'altra, come ad esempio il tragitto che ci conduce da casa al luogo di lavoro e viceversa.

Tuttavia, durante lo svolgimento delle nostre attività quotidiane effettuiamo anche altri spostamenti che ci portano a località non appartenenti a quel piccolo insieme di località definite come importanti. Le probabilità che la destinazione di un nostro tragitto sia una di queste località meno importanti è bassa, ma non nulla.

Inoltre, è evidente che la vicinanza delle diverse località e la velocità e la direzione di spostamento influenzano il nostro tragitto. Se ad esempio un utente avanza lentamente in direzione di una località vicina, anche se quest'ultima risulta essere di importanza relativa per l'utente, le probabilità che essa sia la sua destinazione finale sono comunque maggiori rispetto alle probabilità che intuitivamente assegneremmo ad una località lontana seppur importante. Se invece l'utente avanza a velocità sostenuta ed in direzione tangenziale rispetto ad una località non molto importante, la probabilità che si assegnerebbe intuitivamente a quella località sarebbe bassa.

La metafora qui presentata propone un parallelo tra la modalità intuitiva di assegnazione delle probabilità appena descritta e le leggi fisiche che regolano l'attrazione gravitazionale. Se un oggetto si muove in uno spazio in cui agiscono delle forze gravitazionali prodotte da altri oggetti in posizioni fisse, la traiettoria dell'oggetto verrà modificata dalle forze, si pensi ad esempio ad un asteroide che si muova in un sistema planetario. Riprendendo gli esempi portati precedentemente, se un ODP si trova in un'area soggetta ad una debole forza di attrazione gravitazionale, se è diretto verso il punto in cui si trova l'oggetto che genera il campo di attrazione o se la sua velocità è sufficientemente bassa, l'ODP molto probabilmente verrà attratto verso tale oggetto. Se, invece, la direzione dell'ODP è tangenziale rispetto alla forza di attrazione e la sua velocità e la distanza dal punto di origine della forza gravitazionale sono sufficienti, esso sfuggirà alla forza generata dal campo di attrazione e proseguirà lungo la sua traiettoria.

Supponiamo quindi di conoscere quali sono le località importanti per un dato utente, ovvero di utilizzare una scala di importanza con un valore assegnato a ciascuna di queste e di conoscere la disposizione spaziale di tali località in un piano bidimensionale che rappresenti l'area di interesse in cui l'utente si muove. Supponiamo inoltre di conoscere i dati relativi alla velocità ed alla direzione di movimento dell'utente in un certo istante temporale  $t_0$ . Date tali

informazioni è possibile creare un modello fisico gravitazionale che rappresenti la situazione in cui si trova l'utente all'istante  $t_0$  secondo il modello astratto precedentemente descritto. Si parte da un modello fisico di spazio tridimensionale vuoto e si aggiunge, su uno stesso piano nello spazio tridimensionale, un oggetto fisso per ciascuna delle località importanti secondo la loro disposizione nell'area di interesse, assegnando a ciascun oggetto una massa proporzionale all'importanza della località che rappresenta. La presenza di questi oggetti fissi nello spazio tridimensionale darà origine ad uno schema di forze quale risultato dell'interazione dei campi di attrazione gravitazionale generati dai diversi oggetti. Aggiungendo al modello fisico un oggetto puntiforme di massa trascurabile, il cui vettore di spostamento sul piano su cui sono stati disposti gli oggetti fissi corrisponde alla velocità ed alla direzione dell'utente all'istante  $t_0$ , il movimento di tale oggetto dipenderà dalle forze di attrazione gravitazionale generate dagli altri corpi presenti (vedi Figura 3.1).

FIGURA 3.1

### Generazione del modello

La metafora legata alla fisica gravitazionale è probabilmente quella più intuitiva per questo modello astratto di previsione della traiettoria. Tuttavia le stesse leggi che regolano i campi gravitazionali valgono anche per modelli fisici quali la diffusione del suono e i campi elettrici. Questi ultimi possono risultare di particolare interesse poiché prevedono la presenza sia di potenziali negativi generati dalla presenza di cariche negative, che esercitano forze attrattive (per oggetti di carica positiva) come quelle dei campi gravitazionali, sia di potenziali positivi generati dalla presenza di cariche positive che esercitano forze repulsive (per oggetti di carica positiva), come illustrato in Figura 3.2. Inoltre, questo parallelo permette una più semplice rappresentazione sul piano bidimensionale.

La possibilità di introdurre delle forze repulsive in un modello come quello descritto nel Paragrafo 2.2.1 può inizialmente sembrare contro intuitiva, ma può risultare utile in alcuni casi. Si pensi ad esempio a un sistema di previsione della destinazione installato in un'autovettura. Vi sono alcune zone che l'utente non potrà raggiungere in auto nonostante la sua traiettoria, come ad esempio il centro di un lago, una zona in mare aperto o più semplicemente una zona a traffico esclusivamente pedonale. In questi casi la traiettoria dovrà deviare, ad esempio verso una località che rappresenti il parcheggio che solitamente l'utente utilizza quando deve andare in una zona a traffico pedonale come il centro di una città.

Come si può notare, in questo tipo di modello fisico, basato sui campi elettrici, è più semplice ragionare in termini di potenziale presente in una certa località

piuttosto che di presenza di una certa carica nella località stessa. Inoltre, l'analisi delle abitudini di un utente darà come risultato un valore di importanza da assegnare a ciascuna delle località prese in considerazione e potrebbe non essere banale scegliere un piccolo insieme di punti di interesse disposti sulla superficie, come invece descritto nel Paragrafo 3.2.1. Si può quindi scegliere di interpretare i valori di importanza, assegnati a ciascuna località, come i valori opposti del potenziale elettrico presente in quella data località. In tal modo, maggiore è l'importanza, minore è il valore del potenziale e quindi maggiore è l'attrazione esercitata dalla località.

### 1.2.3 ARDA

Possiamo ora presentare l'algoritmo di previsione basato sul modello astratto precedentemente descritto nel Paragrafo 3.2. In questo paragrafo vengono introdotte le formule utilizzate per eseguire una previsione della traiettoria dell'utente, sia a breve termine che a lungo termine, sulla base dei valori di importanza assegnati alle località secondo un dato indice di stima. Le simulazioni fisiche descritte vengono effettuate in uno spazio bidimensionale a valori continui rappresentante l'area di interesse. Poiché i dati ottenuti dall'analisi dei comportamenti degli utenti sono relativi ad un insieme discreto di località (per le motivazioni illustrate nel Paragrafo 3.2.3), il piano utilizzato nella simulazione deve essere suddiviso mediante una griglia. Durante la simulazione, l'applicazione delle forze in gioco previste dal modello astratto viene operata in modo omogeneo a tutti i punti del piano continuo appartenenti ad una stessa sezione della griglia, ovvero a tutti i punti dello spazio appartenenti ad una stessa località. Si suppone che i valori di importanza utilizzati siano disponibili per mezzo di una struttura dati di tipo matriciale  $M_{imp}$  che rappresenti la griglia delle località.

#### Utilizzo dei valori di importanza

Con l'adozione di un modello gravitazionale, possiamo definire una matrice  $M_{pot}$ , rappresentante l'energia potenziale elettrica di ciascuna località. Ciacun ODP sarà attratto dalle aree a basso potenziale, associate con le località più importanti per l'individuo. Per derivare i valori della matrice  $M_{pot}$  è possibile utilizzare qualsiasi indice di località come ad esempio:

- $\#visits$ : il numero di volte in cui l'utente è stato nella località;
- $avgTime$ : il tempo medio delle visite effettuate dall'utente nella località;
- $totTime$ : il tempo totale passato dall'utente nella località durante le sue visite;

- *spaceRank*: basato su un'analisi dello storico degli spostamenti dell'utente e sull'analisi dell'intorno di ciascuna località.

Al di là degli indici adottati per l'analisi del territorio, importante e comprendere come il risultato di tale procedura sia una matrice di importanza  $M_{imp}$ , che associa i valori più alti alle località dalla maggiore importanza. Dato che il nostro modello fisico utilizza valori di importanza opposti, dobbiamo generare partendo da  $M_{imp}$  la matrice a valori opposti  $M_{pot}$ , rappresentante il potenziale delle locazioni. Per ottenere ciò utilizziamo dunque una funzione monotona decrescente. Nel nostro caso si è scelto di utilizzare per comodità la funzione  $f(x) = -x$ , ma sarebbe stato possibile adottare anche funzioni di tipo polinomiale, logaritmico od esponenziale. A questo punto non rimane altro che calcolare la matrice  $M_{acc}$  delle accelerazioni dipendenti dal potenziale delle aree di interesse. In particolare ogni cella conterrà il vettore accelerazione relativo alla località rappresentata dalla cella della matrice.  $M_{acc}$  è dunque calcolato utilizzando il gradiente:

$$M_{acc} = -\vec{\nabla}(M_{pot}) \quad (1.9)$$

Infine, per ottenere una matrice di accelerazione che abbia dei vettori accelerazione che abbiano una magnitudo dello stesso ordine di quanto osservato nei dati rilevati, andiamo a normalizzare i vettori di accelerazione ottenuti in  $M_{acc}$  in modo che la media delle accelerazioni rilevate nei dati acquisiti corrisponda alla media delle accelerazioni contenute in  $M_{acc}$ . Per fare questo ultimo passo dunque è opportuno seguire la seguente procedura:

1. Rilevare tutte le magnitudo dei vettori di accelerazione dai dati acquisiti e calcolarne il valore medio: *AvgRealMagnitude*
2. Rilevare tutte le magnitudo dei vettori di accelerazione di  $M_{acc}$  e calcolarne il valore medio: *AvgMaccMagnitude*
3. Per ogni vettore accelerazione di  $M_{acc}$  moltiplicare gli elementi del vettore per la costante ricavata da  $\frac{AvgRealMagnitude}{AvgMaccMagnitude}$

FIGURA 3.4

### Calcolo della traiettoria futura

Arrivati a questo punto abbiamo preparato tutte le strutture dati necessarie per il calcolo della traiettoria. E' dunque possibile la previsione della traiettoria utilizzando pochi semplici fattori:

- Un tempo di campionamento, indicante la profondità temporale in secondi della singola previsione (Ad esempio: quanti secondi in avanti prevedere). Nelle nostre rilevazioni abbiamo utilizzato  $\Delta_t = 1$
- La posizione  $(x_1; y_1)$  al tempo corrente  $t_1$
- La posizione  $(x_0; y_0)$  al tempo  $t_0 = t_1 - \Delta_t$
- La matrice di accelerazione  $M_{acc}$ , dove  $M_{acc}[x, y]$  contiene il vettore di accelerazione per la località  $(x, y)$
- Una funzione frenante  $\gamma(M_{imp}, x, y)$ , che ritorni il fattore frenante in base all'importanza della località

Analizzando gli elementi sopra proposti notiamo subito l'introduzione di una funzione frenante, della quale ancora non era stato fatto espressamente cenno nella presentazione del modello adottato. Per comprendere il senso di tale funzione è fondamentale ritornare alla metafora che vede l'ODP come una pallina che rotola su un territorio formato da tante località, ognuna portata ad applicare una forza sulla pallina. Tali forze saranno neutre o repulsive nel caso di località poco importanti o addirittura da evitare (ad esempio le caselle che si trovano al centro di un lago o del mare) saranno invece attrattive nel caso di celle importanti in cui l'utente ha soggiornato a lungo in passato. Proprio in questo ultimo caso, dunque, è necessario che tali celle possano frenare il movimento della pallina rappresentante l'ODP, fino anche a fermarne l'avanzamento. Nel nostro caso abbiamo adottato una funzione frenante che garantisca fattori frenanti che andassero dal 1.5% al 10% del valore ad ogni previsione, a seconda dell'importanza della località percorsa. Tale decisione ha dunque portato alla definizione della seguente funzione:

$$\gamma(M_{imp}, x, y) = 0.015 + 0.085 \times M_{imp}[x, y] \quad (1.10)$$

Una volta definiti i vari elementi del processo previsionale, non rimane che proporre la formula adottata per simulare l'itinerario dell'ODP e quindi per prevedere la posizione  $(x_2, y_2)$  dell'utente al tempo  $t_2 = t_1 + \Delta_t$ . Tale funzione è la Verlet integration formula:

$$\begin{aligned} (x_2; y_2) = & \{ [2 - \gamma(M_{imp}, x_1, y_1)] \times (x_1, y_1) \} \\ & - \{ [1 - \gamma(M_{imp}, x_1, y_1)] \times (x_0, y_0) \} \\ & + \{ M_{acc}[x, y] \times \Delta_t^2 \} \end{aligned} \quad (1.11)$$

Tale formula può essere applicata iterativamente per calcolare le future posizioni dell'ODP in ogni tempo  $t_k = t_1 + (k - 1) \times \Delta_t$ , con  $k \geq 2$ .



### Utilizzo di informazioni aggiuntive

L'algoritmo finora descritto prevede l'utilizzo, come unica fonte di informazioni relative all'importanza delle località, della matrice  $M_{imp}$  costruita in base ai valori di importanza ottenuti dall'analisi del comportamento dell'utente durante il periodo di osservazione. Tuttavia, il modello astratto prevede l'utilizzo di informazioni sull'importanza delle località indipendentemente dalla fonte di tali dati.

Se nella precedente discussione si è presupposto di utilizzare i valori ottenuti dal calcolo dell'algoritmo SpaceRank è tuttavia possibile utilizzare per l'algoritmo di previsione un qualsiasi indice di importanza, costruendone la relativa matrice di valori assegnati alle località dell'area di interesse. Ad esempio, è possibile scegliere di utilizzare dei valori di importanza calcolati solo relativamente ad un dato giorno della settimana o ad un certo periodo di tempo all'interno di una giornata, cercando in tal modo specializzare la previsione in base all'orario in cui viene fatta. Allo stesso modo è possibile scegliere di utilizzare i dati relativi al solo utente in questione oppure quelli relativi a tutti gli utenti osservati, sfruttando l'opportunità di basarsi su un'importanza di tipo globale o condivisa nel caso in cui, ad esempio, non siano disponibili i dati relativi ad un certo utente per una data zona.

Altre tipologie di dati che possono essere integrate in questo algoritmo e sfruttate in alcune particolari situazioni sono quelle deducibili da programmi di tipo agenda o da reti sociali. Molti programmi che offrono la funzionalità di calendario permettono infatti di aggiungere informazioni relative alla località in cui un dato evento avrà luogo. L'importanza relativa a tali tipi di località può quindi essere aumentata durante un dato arco temporale che include l'evento stesso. Le informazioni relative al posizionamento di amici o colleghi può essere sfruttata in modo simile, presupponendo che la destinazione dell'utente possa essere influenzata dalla presenza di conoscenti in alcune località.

La flessibilità del modello nella codifica dei dati da utilizzare come informazioni sull'importanza delle località viene sottolineata dalla semplicità con la quale le diverse tipologie di dati possono essere integrate in un'unica valutazione. Due o più fonti di dati, o metodologie di analisi, possono infatti essere sovrapposte, mediante una combinazione lineare delle matrici di importanza relative alle singole fonti, generando un'unica matrice:

$$M_{imp} = \alpha_1 M_{fonte1} + \alpha_2 M_{fonte2} + \dots \quad (1.12)$$

dove  $\alpha_1 M_{fonte1} + \alpha_2 M_{fonte2} + \dots$  sono le matrici relative alle singole fonti ed  $\alpha_1, \alpha_2, \dots$  sono i rispettivi pesi utilizzati per la combinazione lineare.



# Capitolo 2

## Conversione e sviluppo

### 2.1 Analisi e scelte implementative

Java e Python sono due linguaggi di programmazione simili ma diversi tra loro nati e progettati per necessità differenti. Java nato agli inizi degli anni '90, è uno dei linguaggi di programmazione più conosciuti ed apprezzati negli decenni passati. Ha avuto un notevole successo grazie all'esposizione di internet e la possibilità di creare applicazioni client-server indipendenti dalla piattaforma. Simile al C++ come sintassi di base ma senza alcune sue caratteristiche che potevano creare delle criticità a livello di progettazione (come l'aritmetica dei puntatori, ecc)[9], mentre le caratteristiche object oriented sia a C++ ma soprattutto all'Objective C.

Il codice Java deve essere prima compilato per ottenere in cosiddetto *bytecode* che poi verrà eseguito attraverso una fase di interpretazione ad opera della Java Virtual Machine. Proprio questo procedimento riesce a slegare i programmi dall'ambiente di compilazione ed esecuzione (da cui il motto *Write once, Run everywhere*).

Python, nato sempre agli inizi degli anni '90, è un un linguaggio multi-paradigma, che fa della dinamicità, semplicità e flessibilità i suoi principali obiettivi. Supporta la programmazione Object oriented e molte caratteristiche di programmazione funzionale e riflessione. Una sua caratteristica che lo contraddistingue è la non tipizzazione delle variabili e l'esecuzione in *runtime*.

#### 2.1.1 Conversione

Sono proprio le differenze appena descritte che si sono contraddistinte durante la conversione del progetto da Python a Java. La struttura più rigida

di Java ha richiesto un'analisi delle variabili, delle funzioni e degli oggetti utilizzati che, a volte, ha richiesto una conversione della tipologia delle variabile oppure una divisione per ogni tipologia utilizzata dal programma.

Sebbene questa rigidità ha richiesto un'analisi preventiva del codice, in seguito ha reso lo sviluppo più agevole in quanto il flusso dei dati rimane coerente visto che non può variare di tipologia.

### 2.1.2 Unificazione dei valori di default

Nel progetto originale si era preferito dividere sia l'esecuzione dei test tra il percorso di Udine con quello ad Atlanta, sia il calcolo delle matrici di importanza con l'algoritmo SpaceRank dagli altri metodi, questo perchè si è preferito concentrare lo sviluppo degli algoritmi e dei test per i casi specifici. Tale approccio ha portato alla realizzazione di quattro distinti flussi di codice simili tra loro ma con variabili e funzioni indipendenti e non riutilizzabili tra loro.

Durante l'analisi iniziale, necessaria per definire funzioni e variabili, si è preferito unificare le procedure simili così da semplificare e diminuire il codice necessario per il programma. Anche le strutture dati sono risultate simili e optato per unificare la gestione del calcolo della matrice di importanza.

### 2.1.3 Modifiche fatte

Durante lo sviluppo dell'applicativo si sono voluti apportare dei cambiamenti a livello di calcolo.

#### Calcolo della distanza

Nella versione precedente, per calcolare le distanze tra due punti successivi, ottenuti dalle rilevazioni, veniva usato il calcolo tra 2 punti. Nel nostro caso non possiamo considerare i nostri spostamenti su un piano ma spostamenti su una superficie sferica. Per questo si è preferito sostituire

$$d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2} \quad (2.1)$$

con il calcolo della distanza in una superficie sferica

$$d = r_{earth} * \arccos((\sin lat_1 * \sin lat_2) + (\cos lat_1 * \cos lat_2 * \cos(lat_1 - lat_2))) \quad (2.2)$$

Questa variazione rende la distanza calcolata più vicina alla realtà, soprattutto quando i due punti sono molto lontani tra loro, in alcuni casi limite, può ancora non essere precisa.

Negli spostamenti presi in esame questo cambiamento porta un miglioramento marginale ma si è preferito introdurla soprattutto per avere una base di sviluppo più accurata.

### Calcolo della matrice accelerazione

Nel calcolo delle matrici ARDA, per ottenere la matrice delle accelerazione  $M_{acc}$  si esegue, sulla matrice  $M_{imp}$ , una funzione gradiente per calcolare i valori del vettore in tutte le zone. Come si può vedere nei FIGURA xy, la matrice generata ha ottimi risultati con punti di importanza distanti tra loro ma con punti vicini il calcolo del vettore ha qualche incongruenza nelle zone adiacenti. Utilizzando l'algoritmo di Sobel, questo distribuisce con maggior equità le forze anche in presenze di molti punti di interessi vicini tra loro.

Sia nel precedente progetto che in questo, la matrice di accelerazione viene calcolata dopo un solo processo della matrice  $M_{imp}$  calcolando le forze solo nelle zone adiacenti a quelle con dei valori di interesse. Pensando proprio all'idea su cui si basa l'utilizzo delle matrici di accelerazione si può capire quanto possa essere limitativo eseguire questo calcolo solo in queste zone. Questo può portare ad un'eventuale sviluppo e confronto con il calcolo della matrice di accelerazione con più iterazione sulla matrice risultante

$$M_{acc} = G^n(M_{imp}) \quad (2.3)$$

## 2.2 Interfaccia Java

Altro punto della progetto è creare un'interfaccia user-friend per poter eseguire i setup e visualizzare i risultati in modo semplice e veloce. Nel progetto precedente bisognava eseguire i setup dei file, directory e impostazioni direttamente nei vari file del codice.

FIGURA xy

Adesso l'utente ha la possibilità di impostare:

1. i file mediante una semplice selezione tramite un finder navigando nel filesystem
2. selezionare le dimensione delle celle e gli indici utilizzati per il calcolo
3. visualizzare un plot della matrice di importanza.

Per l'esecuzione dei test si è scelto di dividere il calcolo dal salvataggio dei risultati mediante i file CSV già implementati nella versione precedente, con la possibilità di visualizzare solamente il dato preso in esame. Proprio per rendere facilmente usufruibile la funzione di visualizzazione dei dati, la sezione dei grafici è divisa in varie schede (come si può vedere dall'immagine) generate in base alle opzioni selezionate.

### 2.2.1 Visualizzazione plot matrici

Questa funzionalità ha però tolto la possibilità di selezione multipla della grandezza delle zone di importanza e impostato un limite di 2 possibili tipi di indice.

FIGURA XY

Infatti la visualizzazione e la gestione delle schede sarebbe stata troppo dispersiva visti la possibilità di generare 25 casi separati con almeno 7 grafici differenti per ognuno di essi ed un totale di 175 schede massime. Con le limitazioni imposte si arriva a un massimo di 14 schede divise in 2 righe, sufficienti per avere subito a dei grafici e poter fare un confronto veloce tra 2 tipi di indice differente.

FIGURA XY

Questa piccola variazione però non influenza la generazione dei file CSV con i risultati. Essi non vengono cancellati e, con il lancio di tutte le procedure mediante l'interfaccia, possono essere facilmente reperibili per effettuare analisi direttamente dai dati che normalmente si visualizzano nei grafici.

### Tempistiche di esecuzione

- Differenze tra Java e Python (semplice benchmark) !! Differenze tra dispositivi (PC vs RaspberryPi)

## Capitolo 3

# Comparative sui risultati ottenuti

### 3.1 Matrici d'importanza

#### 3.1.1 Dati Python

#### 3.1.2 Dati Java

### 3.2 ARDA

#### 3.2.1 Dati Python

#### 3.2.2 Dati Java

### 3.3 Valutazioni complessive

Come già detto nell'introduzione e nel capitolo 2, le varie modifiche apportate al codice hanno portato differenze marginali al livello di risultati complessivi. Il limitato miglioramento è dovuto alla dimensione delle aree prese in esame, troppo piccole per poter vedere i miglioramenti ottenibili delle nuove funzioni introdotte.

Questo però non va incriminato alla scelta dei dati ma proprio alla natura dei dati da analizzare, che cerca di prevedere le distanzioni su una serie di spostamenti ottenuti monitorando degli utenti nelle loro spostamenti abituali. Ed è proprio la natura ripetitiva dei spostamenti a rendere piccola la zona di interesse, visto che difficilmente una persona compie spostamenti giornalieri su un'area di centinaia di chilometri quadrati.





# Bibliografia

- [1] A.Dey, *Understanding and using context*, Personal and Ubiquitous Computing, vol. 5, no. 1, pp 4-7, 2001
- [2] Chaoming Song, Zehui Qu, Nicholas Blumm, Albert-Laszlo Barabasi. *Limits of Predictability in Human Mobility*, Science 19 February 2010: Vol.327 . no 5968, pp.1018-1021
- [3] Luca Snaidero, *Valutazione sperimentale dell'algoritmo ARDA per la previsione di traiettorie*, 2009
- [4] J. Krumm and E. Horvitz. *Predestination: Inferring destinations from partial trajectories ubicomp*. In Springer, editor, Lecture Notes in Computer Science, volume 4206, pages 243-260, 2006.
- [5] D. Ambrosin and A. Sciomachen. *A gravitational approach for locating new services in urban areas*. In Proceedings of the 16th Mini - EURO Conference and 10th Meeting of EWGT, pages 194-199, Poznan, Poland, 2005. Poznan University of Technology.
- [6] M. C. Gonzalez, C. A. Hidalgo, and A. L. Barabasi. *Understanding individual human mobility patterns*. Nature, 435(7196):779-782, 2008.
- [7] L. Page, S. Brin, R. Motwani, and T. Winograd. *The pagerank citation ranking: Bringing order to the web*. Technical report, Stanford Digital Library Technologies Project, 1998.
- [8] S. De Sabbata, *Pre-destinazione: modelli ed esperimenti per la previsione di traiettorie*, Tesi laurea specialistica Universita degli Studi di Udine.
- [9] *The Java(tm) Language Environment*  
<http://java.sun.com/docs/white/langenv/Simple.doc2.html>